



Dati  $N$  vettori  $\in X^{\mathbb{F}}$   $\rightarrow$  trovare  $K \subseteq \mathbb{F}$  vettori ortogonali.



1) Calcolare la matrice  $A$ , coi valori sistemati sottraendo al Dataset  $D$  la sua media  $M$ .



2) Calcoliamo la matrice della covarianza partendo da A.

$$\text{COV}(X, Y) = \frac{\sum_{i=1}^N (x_i - \bar{X})(y_i - \bar{Y})}{N-1}$$

$$\text{COV}(X, Y) = \begin{bmatrix} & & & & \\ & & & & \\ & & & & \\ & & & & \\ & & & & \end{bmatrix} \begin{matrix} \text{f} \\ \text{f} \\ \text{f} \\ \text{f} \\ \text{f} \end{matrix} = C$$

Dove  $c_{ij} = \text{Cov}(i, j)$

$$C = \frac{AA^T}{n-1}$$

Possiamo usare questa formula perché abbiamo normalizzato A, in modo tale che la media delle dimensioni ( $\text{media}(\text{riga}_i)$ ) è pari a zero

3) Calcolare gli autovalori di  $C: \lambda_1 \dots \lambda_f$  e i rispettivi autovettori. Possiamo scartare gli autovettori con autovalore vicino a 0

$$\Sigma' = \begin{bmatrix} & & & & & & \\ & & & & & & \\ & & & & & & \\ & & & & & & \\ & & & & & & \\ & & & & & & \\ & & & & & & \end{bmatrix}$$

$$\Sigma'' = \begin{bmatrix} & & & & \\ & & & & \\ & & & & \\ & & & & \\ & & & & \end{bmatrix}$$

} Per esempio eliminiamo gli ultimi due.

4) Trasformiamo il dataset in  $F = \Sigma^T A$

$$\Sigma \in X^{5 \times 3}, A \in X^{5 \times n}$$

$$\Sigma^T \in X^{3 \times 5}$$

$$F = \begin{matrix} \Sigma^T \\ \begin{bmatrix} & & & & \\ & & & & \\ & & & & \\ & & & & \\ & & & & \end{bmatrix} \end{matrix} \times \begin{matrix} A \\ \begin{bmatrix} | & | & | & | & | & \dots & | \\ | & | & | & | & | & \dots & | \\ | & | & | & | & | & \dots & | \\ | & | & | & | & | & \dots & | \\ | & | & | & | & | & \dots & | \end{bmatrix} \end{matrix} = \begin{matrix} F \\ \begin{bmatrix} | & | & | & | & | & \dots & | \\ | & | & | & | & | & \dots & | \\ | & | & | & | & | & \dots & | \\ | & | & | & | & | & \dots & | \\ | & | & | & | & | & \dots & | \end{bmatrix} \end{matrix}$$



## PCA

Partendo da un dataset con  $M$  feature, l'obiettivo della PCA è quello di trovare  $K$  vettori ortogonali di dimensione  $M$  che meglio rappresentano il dataset

$$K \leq M$$

### Esempio:

Supponiamo di avere il seguente dataset:

altezza	Peso	età
---------	------	-----

Supponiamo che il dataset contenga queste info per 10 persone. Quindi abbiamo dimensione  $10 \times 3$

### STEP 1: Normalizzazione i dati

Trasformare ogni attributo in una variabile con media = 0 e varianza = 1.

	Altezza	Peso	Età
1	1.73	62	27
2	1.68	65	31
3	1.75	70	24
4	1.70	68	28
5	1.80	73	32
6	1.85	75	26
7	1.62	55	30
8	1.76	69	27
9	1.72	71	29
10	1.78	74	33

$$\text{Altezza Media} = 1,74$$

$$\text{Peso Medio} = 68,20$$

$$\text{Età Media} = 28,70$$

$$\text{Deviazione Standard Altezza} = 0,0816$$

$$\text{Deviazione Standard Peso} = 6,035$$

$$\text{Deviazione Standard Età} = 2,297$$

Per ogni valore calcoliamo:  $\vec{VAL} - \vec{MEDIA}$

Il dataset dopo la trasformazione appare così:

A =

	Altezza	Peso	Età
1	-0,01	-6,20	-1,70
2	-0,06	-3,20	2,30
3	0,01	1,80	-4,70
4	-0,04	-0,20	-0,70
5	0,06	4,80	3,30
6	0,11	6,80	-2,70
7	-0,12	-13,20	1,30
8	0,02	0,80	-1,70
9	-0,02	2,80	0,30
10	0,04	5,80	4,30

## STEP 2: Calcolare la matrice di Covarianza

Partendo dal dataset trasformato, calcoliamo la matrice di covarianza.

Considerando la formula della covarianza fra due attributi  $X$  e  $Y$

$$\text{COV}(X, Y) = \frac{\sum_{i=1}^N (x_i - \bar{x})(y_i - \bar{y})}{N-1}$$

La matrice di covarianza si calcola  $C_{ij} = \text{COV}(i, j)$  dove  $i$  e  $j$  rappresentano i vari attributi.

Sulla diagonale della matrice ci saranno i valori  $\text{COV}(i, i)$ .

C =

	Altezza	Peso	Età
Altezza	0	0,32	-0,05
Peso	0,32	0	-0,58
Età	-0,05	-0,58	0



### STEP 3: Calcolare gli autovalori di C

$$\lambda_1 = -0,6422$$

$$\lambda_2 = -0,0422$$

$$\lambda_3 = 0,6844$$

Se qualche autovalore è 0 o molto vicino a 0 possiamo scartare questi autovalori e i corrispondenti autovettori.

### STEP 4: Trasformare il dataset con la nuova base

Chiamiamo  $\Sigma$  la matrice degli autovettori:

$$\Sigma = \begin{pmatrix} 0,31 & 0,88 & -0,37 \\ -0,72 & -0,04 & -0,70 \\ -0,62 & 0,48 & -0,62 \end{pmatrix} \begin{matrix} v_1 \\ v_2 \\ v_3 \end{matrix}$$

$$\lambda_1 = -0,6422$$

$$\lambda_2 = -0,0422$$

$$\lambda_3 = 0,6844$$

La trasformazione sarà:  $F = \Sigma^T A$



La matrice A va presa capovolta, con le tuple sulle colonne e gli attributi sulle righe.

$$F = \begin{bmatrix} 5.5073 & 0.8425 & 1.6446 & 0.5680 & -5.4857 & -3.1609 & 8.6245 & 0.4930 & -2.2028 & -6.8336 \\ -0.5741 & 1.1821 & -2.3222 & -0.3632 & 1.4433 & -1.4765 & 1.0546 & -0.8316 & 0.0131 & 1.8656 \\ 3.2666 & 3.6642 & -4.1513 & -0.2775 & -1.3258 & -6.4320 & 10.0225 & -1.6111 & -1.7544 & -1.3975 \end{bmatrix}$$

F è il dataset trasformato, **MA NON RIDOTTO**.  
Non si è ridotto perché non ho eliminato nessun  $v_i$

Una volta trovato  $F$ , posso scegliere di eliminare le righe, corrispondenti agli attributi i cui autovalori sono bassi.

Difatti la PCA tende a trasformare il punto di vista del dataset in modo tale che la varianza rispetto a un dato autovettore sia la minima. Questo ci si evince dagli autovalori che danno l'idea di quanto una feature è rappresentata bene dalla direzione del autovettore



dove  $v_1$  avrà  $\lambda_1$  vicino a 1,  $\lambda_2 \approx 0$