

# BAYESIAN BELIEF NETWORK

È difetto una miglioria del classico Bayesian, che si modella alla dipendenza fra vari attributi.

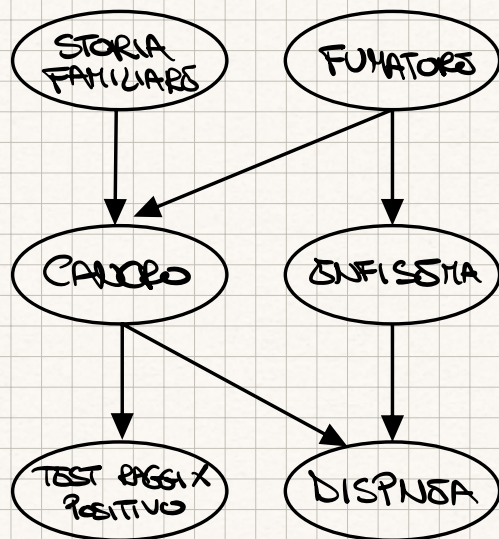
Usa l'idea di grafo dire:

**NOI:** Variabili aleatorie (Random Variable)

**LINK:** Dipendenze fra le variabili

Questo grafo non ha cicli.

Esempio



Conditional Probability Tab  
per la variabile CANCRO

	SF	SF	NSF	NSF
	S	NS	S	NS
C	0,8	0,5	0,7	0,1
NC	0,2	0,5	0,3	0,9

$P(\text{Cancro} = \text{si} \mid \text{StoriaFamigliare} = \text{yes}, \text{Fumatore} = \text{yes}) = 0.8$

$P(\text{Cancro} = \text{no} \mid \text{StoriaFamigliare} = \text{no}, \text{Fumatore} = \text{no}) = 0.9$

Una Belief Network ha una **Conditional Probability Table** per ogni variabile  $Y$ . La CPT per una variabile  $Y$  specifica la distribuzione di probabilità condizionata

$$P(Y \mid \text{Parents}(Y))$$


La tabella dell'esempio di sopra specifica la CPT per la variabile CANCRO i cui parenti sono STORIA FAMILIARE e FUMATORE.

Prendiamo  $X = (x_1 \dots x_n)$  le tuple da analizzare, e diciamo che ogni tuple è descritta dagli attributi  $Y_1 \dots Y_m$ . Ogni variabile è indipendente da chi non è direttamente collegato con un link nel grafo, questo fa in modo che possiamo rappresentare l'intera distribuzione di probabilità condizionata con la seguente equazione:

$$P(x_1 \dots x_n) = \prod_{i=1}^n P(x_i | \text{Parents}(Y_i))$$

Dove per  $\text{Parents}(Y_i)$  si intendono le entrate della Conditional Probability Table (CPT). Difatti la formula rappresenta la distribuzione della joint probability, ovvero la probabilità che una determinata combinazione dei valori di  $X$  si verifichi.

### Esempio



Non considerando la rete, supponendo l'indipendenza fra tutte le variabili:

$$P(A, B, C, D, E) = P(A | B, C, D, E) \cdot P(B | C, D, E) \cdot P(C | D, E) \cdot P(D | E) \cdot P(E)$$

Considerando la rete, quindi le dipendenze:

$$P(A, B, C, D, E) = P(A | B) \cdot P(B | C, E) \cdot P(C | D) \cdot P(D) \cdot P(E)$$



Di fatto il classificatore di tipo Network Bayesian, presuppone che uno o più di uno dei nodi nella rete siano la classe-label target.

Il classificatore può anche dare in output la distribuzione di probabilità che dato un esempio quale è la probabilità di essere classificato con la classe  $C_1$  piuttosto che  $C_2$ . Distribuzione di probabilità fra le classi.

### SCENARI:

- 1) Abbiamo la struttura della rete e le variabili osservate: bisogna solo calcolare la CPT.
- 2) Rete conosciuta e solo qualche variabile nota, non tutte. Possiamo usare il gradiente discendente per aggiornare le CPT entry o pesi. Questi pesi sono inizializzati randomicamente.
- 3) Rete sconosciuta, variabili osservabili: Ricostruire la rete attraverso lo spazio dei modelli. Credo che semplicemente bisogna valutare la dipendenza fra le variabili.
- 4) Se non conosci nulla ti attacchi.

## METODO DSC GRADIENTS DESCENDENT

Prendiamo in considerazione il dataset  $D$  con le tuple  $X_1 \dots X_{|D|}$ .

Indichiamo con  $w_{ijk}$  le entrate della CPT o pesi. Il peso  $w_{ijk}$  fa riferimento all'entrata della CPT per la variabile  $Y_i = y_{ij}$  che ha i parenti  $U_i = u_{ik}$ .

$$w_{ijk} = P(Y_i = y_{ij} \mid U_i = u_{ik})$$

All'inizio tutti i pesi sono scelti randomicamente. L'algoritmo funziona scalando in modo greedy la distribuzione di probabilità:

$$P_w(D) = \prod_{d=1}^{|D|} P_w(X_d)$$

Cercando di fatti l'ottimo. Per farlo bisogna seguire il gradiente negativo del  $\ln(P_w(D))$ .

A ogni iterazione i passi da fare sono:

1) ~~Calcolare~~ il gradiente:

$$\frac{\partial \ln(P_w(D))}{\partial w_{ijk}} = \sum_{d=1}^{|D|} \frac{P(Y_i = y_{ij}, U_i = u_{ik} \mid X_d)}{w_{ijk}}$$

2) Aggiornare i pesi lungo il gradiente

$$w_{ijk} = w_{ijk} + \epsilon \cdot \frac{\partial \ln(P_w(D))}{\partial w_{ijk}}$$

Dove con  $\epsilon$  indichiamo la dimensione del passo.



3) Rinnormalizzare i pesi:

Essendo probabilità devono stare fra 0 e 1 e

$$\text{per } \sum_j w_{ijk} = 1 \quad \forall i, k.$$