

PROBLEMI VINCOLATI

Consideriamo il solito problema di ottimizzazione \mathcal{P} :

$$\begin{cases} \min f(x) & \forall x \in X \\ X = \{x \in \mathbb{R}^m : g_i(x) \leq 0, h_i(x) = 0, \forall i, j = 1, \dots\} \end{cases}$$

Con f, g e h continue e differenziabili.

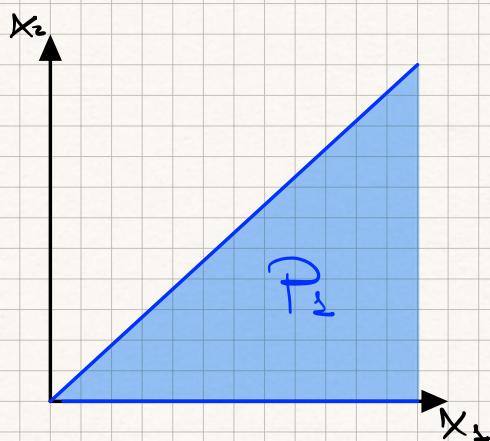
CONO TANGENTE

Definiamo il cono tangente in $x^* \in X$ come:

$$T_C(x^*) = \left\{ d \in \mathbb{R}^m : \exists \{z_k\} \subset X, \exists \{t_k\} > 0, z_k \rightarrow x^*, t_k \rightarrow 0, \lim_{k \rightarrow \infty} \frac{z_k - x^*}{t_k} = d \right\}$$

Esempio

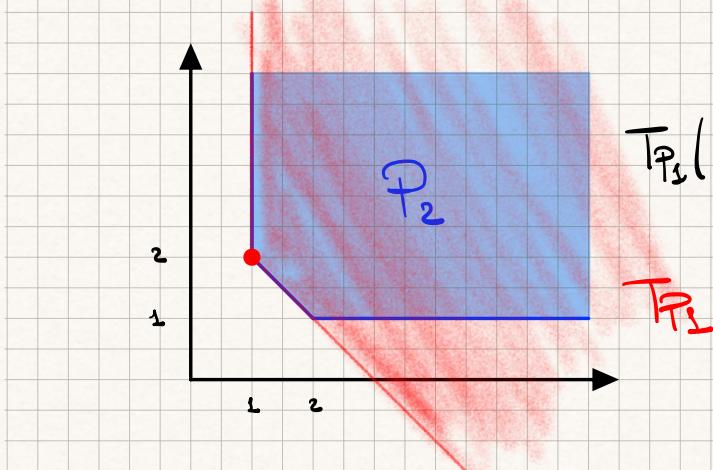
$$\mathcal{P}_1 = \{x \in \mathbb{R}^2 : x_2 \leq x_1, x_2 > 0\}$$



$$T_{\mathcal{P}_1}(0,0) = \mathcal{P}_1$$

δ_{sempio}

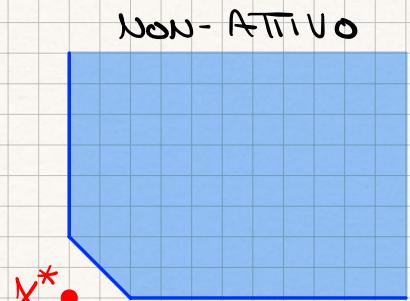
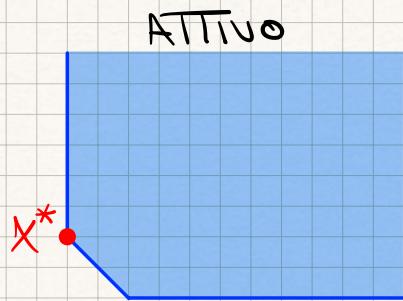
$$P_1 = \{x \in \mathbb{R}^2 : x_1 \geq 0, x_2 \geq 1, x_1 + x_2 \geq 3\}$$



$$T_{P_1}(1, 2) = \{d \in \mathbb{R}^2 : d_1 \geq 0, d_2 \geq 0\}$$

SST DI DISIEQUAZIONI ATTIVE

Si dice che un set P , formato da vincoli a moci disiequazione, è **attivo** rispetto ad $x^* \in X$ se "tocco" la disiequazione:



Definiamo il set $P(x^*) = \{j : g_j(x^*) = 0\}$

FIRST ORDER FEASIBLE DIRECTION CONS

Definiamo il set $D(x^*)$:

$$D(x^*) = \left\{ d \in \mathbb{R}^n : \begin{array}{ll} d^T \nabla g_f(x^*) \leq 0 & \forall f \in \mathcal{A}(x^*) \\ d^T \nabla h_k(x^*) = 0 & \forall k = 1 \dots p \end{array} \right\}$$

\bar{S} è il cono di direzioni ammissibili del primo ordine.

DEFINIZIONE - Abadie constraint qualification (ACQ)

Diciamo che la qualificazione dei vincoli di Abadie è valida per un punto ammissibile $x^* \in X$ se:

$$T_x(x^*) = D(x^*)$$

Il vettore con tangente $T_x(x^*)$ può essere separato con i gradienti dei vincoli $(\nabla g, \nabla h)$

TEOREMA

1) Vincoli affine

Se g_f e h_k sono funzioni affini $\forall f, k$, ALLORA la condizione ACQ è valida.

2) Slater condition

Se g_f è convessa $\forall f=1 \dots m$, h_k è affine $\forall k=1 \dots p$ e $\exists \bar{x} \in X : g(\bar{x}) < 0$ e $h(\bar{x}) = 0$ ALLORA la condizione ACQ è valida $\forall x \in X$.

3) Dipendenza Lineare dei gradienti dei vincoli attivi.

Se $x^* \in X$ e i vettori:

$$\nabla g_i(x^*) \quad \forall i \in A(x^*)$$

$$\nabla h_k(x^*) \quad \forall k=1 \dots p$$

sono linearmente indipendenti ALLORA la condizione ACQ è valida in x^* .

TEOREMA - KKT

Se x^* è un minimo locale e la condizione ACQ è verificata ALLORA $\exists \lambda^* \in \mathbb{R}^m$, $\exists \mu^* \in \mathbb{R}^p$: (λ^*, μ^*, x^*) soddisfano il seguente sistema

$$\left\{ \begin{array}{l} \nabla f(x^*) + \sum_{i=1}^m \lambda_i^* \nabla g_i(x^*) + \sum_{j=1}^p \mu_j^* \nabla h_j(x^*) = \emptyset \\ \lambda_i^* g_i(x^*) = \emptyset \quad \forall i=1 \dots m \\ \lambda^* \geq \emptyset \\ g(x^*) \leq \emptyset \\ h(x^*) = \emptyset \end{array} \right.$$

LAGRANGIANA

Definiamo la funzione Lagrangiana $L: \mathbb{R}^m \times \mathbb{R}^m \times \mathbb{R}^p$:

$$L(x, \lambda, \mu) := f(x) + \sum_{i=1}^m \lambda_i g_i(x) + \sum_{j=1}^p \mu_j h_j(x)$$

Considerando la Lagrangiana il sistema KKT diventa

$$\left\{ \begin{array}{l} \nabla_x L(x, \lambda, \mu) = \emptyset \\ \lambda_i g_i(x) = \emptyset \quad \forall i=1 \dots m \\ \lambda \geq 0 \\ h(x) = \emptyset \\ g(x) \leq \emptyset \end{array} \right.$$

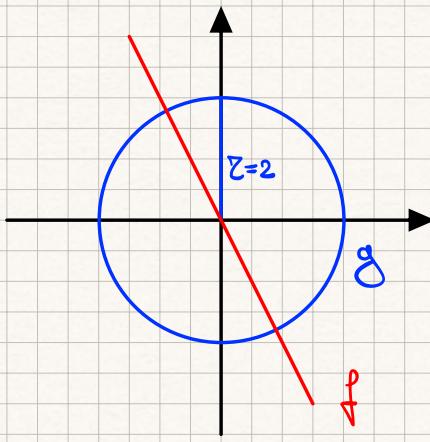
Nota: la condizione $\lambda_i g_i(x) = \emptyset$ può essere riscritta in forma vettoriale:

$$\lambda^T g(x) = \emptyset \quad \circ \quad \langle \lambda, g(x) \rangle = \emptyset$$

Esempio

$$\begin{cases} \min f(x) = 2x_1 + x_2 \\ X \in \mathbb{R}^2 : x_1^2 + x_2^2 \leq 4 \end{cases}$$

La regione X è chiusa e limitata, $f(x)$ è continua in \mathbb{R}^2 quindi anche in $X \subset \mathbb{R}^2$, da qui vale il teorema di Weierstrass: $\exists x^* \in X$ minimo globale di $f(x)$ in X .



La Lagrangiana è:

$$L(x, \lambda, \mu) = 2x_1 + x_2 + \lambda(x_1^2 + x_2^2 - 4)$$

Da cui il KKT:

$$\begin{cases} \begin{pmatrix} 2 + \lambda 2x_1 \\ 1 + \lambda 2x_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \\ \lambda(x_1^2 + x_2^2 - 4) = 0 \\ \lambda > 0 \\ x_1^2 + x_2^2 - 4 \leq 0 \end{cases} \Rightarrow \begin{cases} 2 + \lambda 2x_1 = 0 \\ 1 + \lambda 2x_2 = 0 \\ \lambda(x_1^2 + x_2^2 - 4) = 0 \\ \lambda > 0 \\ x_1^2 + x_2^2 - 4 \leq 0 \end{cases}$$

Note che per $\lambda = 0$ il sistema è impossibile perché la prima equazione verrebbe $2 = 0$.

Risolvendo il sistema, abbiamo che:

$$\begin{cases} x_1 = -\frac{1}{\lambda} \\ x_2 = -\frac{1}{2\lambda} \\ x_1^2 + x_2^2 = 4 \\ \lambda > 0 \end{cases} \Rightarrow \frac{1}{\lambda^2} + \frac{1}{4\lambda^2} = 4 \Rightarrow \lambda = \pm \frac{\sqrt{5}}{4}$$

Da cui troviamo $x_1 = -\frac{4\sqrt{5}}{5}$, $x_2 = -\frac{2\sqrt{5}}{5}$

Per cui l'ottimo è $x^* = \left(-\frac{4\sqrt{5}}{5}, -\frac{2\sqrt{5}}{5}\right)$

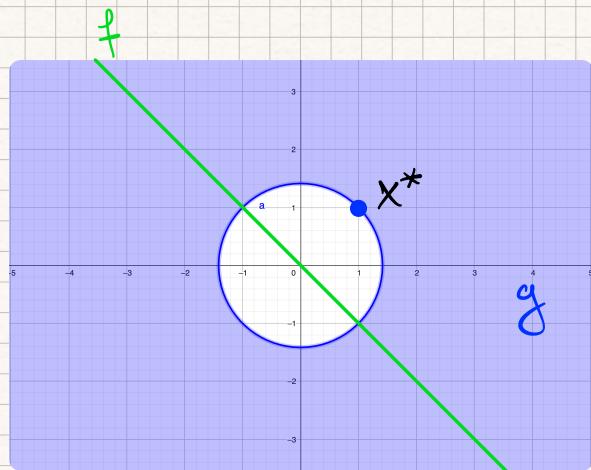
Attenzione: Il KKT è una condizione **NECESSARIA** ma non **SUFFICIENTE**, rispetto all'ottimalità.

Esempio

$$\begin{cases} \min x_1 + x_2 \\ -x_1^2 - x_2^2 + 2 \leq 0 \end{cases}$$

Attraverso la risoluzione del KKT ottieniamo a ottenere

$$x^* = (1, 1) ; \lambda^* = \frac{1}{2}$$



Perciò x^* è un minimo locale. Infatti non esiste una sfera $B(x^*, \varepsilon)$ tale che $f(x^*)$ sia il minimo di tutti i punti $x \in B$.

TEOREMA - KKT PER PROBLEMI CONVESI

Se il problema di ottimizzazione \mathcal{P} è convesso e (x^*, λ^*, μ^*) risolve il KKT ALLORA x^* è un ottimo globale.

Dimostrazione

Assumiamo che (x^*, λ^*, μ^*) risolve il KKT, allora:

$$\nabla_x L(x^*, \lambda^*, \mu^*) = \emptyset$$

Allora abbiamo trovato il punto x^* minimo globale per L , dato che il nostro problema è convesso, da cui:

$$L(x^*, \lambda^*, \mu^*) \leq L(x, \lambda^*, \mu^*) \quad \forall x \in \mathbb{R}^m$$

Riscrivendo L :

$$f(x^*) + (\lambda^*)^T g(x^*) + (\mu^*)^T h(x^*) \leq f(x) + (\lambda^*)^T g(x) + (\mu^*)^T h(x)$$

RILASSAMENTO LAGRANGIANO

Chiamiamo $v(\mathcal{P})$ l'ottimo valore per \mathcal{P} .

Dato $\lambda \geq 0$ e $\mu \in \mathbb{R}^q$, il problema

$$\left\{ \begin{array}{l} \inf_{x \in \mathbb{R}^n} L(x, \lambda, \mu) \end{array} \right.$$

È detto *Lagrangian Relaxation* di \mathcal{P} .

Invece:

$$\varphi(\lambda, \mu) = \inf_{x \in \mathbb{R}^n} L(x, \lambda, \mu)$$

È detto *Lagrangian dual function*.

Questa ultima funzione φ è:

1) Concava, poiché è l'estremo inferiore di un set affine

2) Potrebbe succedere che $\varphi(\lambda, \mu) = -\infty$ per qualche punto

3) Potrebbe non essere differenziabile in qualche punto

TEOREMA

$$\forall \lambda \geq 0 \text{ e } \mu \in \mathbb{R}^p \Rightarrow \varphi(\lambda, \mu) \leq V(P)$$

Dimostrazione

Se prendiamo $x \in X$, per definizione abbiamo che:

$$g(x) \leq 0 \quad h(x) = 0$$

Allora:

$$L(x, \lambda, \mu) = f(x) + \sum_{i=1}^m \lambda_i g_i(x) \leq f(x)$$

Ma dato che per definizione $\varphi(\lambda, \mu) = \inf_{x \in X} L(x, \lambda, \mu)$

$$\inf_{x \in X} (L(x, \lambda, \mu)) \leq \inf_{x \in X} (L(x, \lambda, \mu)) \leq \inf_{x \in X} (f(x)) = V(P)$$

Assumendo che P abbia un valore ottimo finito.

PROBLEMA DUALE LAGRANGIANO

Definiamo il problema

$$\begin{cases} \max \varphi(\lambda, \mu) \\ \lambda \geq 0 \end{cases} = D$$

Lagrangian Dual Problem

In altre parole il duale D consiste nel trovare il miglior limite inferiore di $V(P)$.

Note: D è sempre un problema convesso, anche quando P non lo è. È un problema dove bisogna massimizzare

una funzione concava in un set convesso

PROGRAMMAZIONE LINEARE

Abbiamo il problema primale P :

$$\begin{cases} \min c^T x \\ Ax \geq b \end{cases}$$

La lagrangiana

$$L(x, \lambda) = c^T x + \lambda^T (Ax - b) = \lambda^T b + (c^T - \lambda^T A) x$$

La funzione doppia

$$\varphi(\lambda) = \inf_{x \in \mathbb{R}^m} L(x, \lambda) = \begin{cases} -\infty & c^T - \lambda^T A \neq \emptyset \\ \lambda^T b & c^T - \lambda^T A = \emptyset \end{cases}$$

Problema doppio D :

$$\begin{cases} \max \varphi(\lambda) \\ \lambda \geq 0 \end{cases} \Rightarrow \begin{cases} \max \lambda^T b \\ \lambda^T A = c^T \\ \lambda \geq 0 \end{cases}$$

Quest'ultimo è un problema di programmazione lineare

LEAST NORM SOLUTION OF LINEAR EQUATION

Definiamo il problema primale P

$$1) \begin{cases} \min \frac{1}{2} x^T x \\ Ax = b \end{cases}$$

$$2) L(x, \mu) = \frac{1}{2} x^T x + \mu(Ax - b)$$

$$3) \varphi(\mu) = \inf_{x \in \mathbb{R}^m} L(x, \mu) \equiv \min_{x \in \mathbb{R}^m} L(x, \mu) = A^T \mu$$

L Quadratica e strongly convex

$$\varphi(\mu) = -\frac{1}{2} \mu^T A A^T \mu + b^T \mu$$

4) Duale

$$\max_{\mu \in \mathbb{R}^n} -\frac{1}{2} \mu^T A A^T \mu + b^T \mu$$

TEOREMA

Per qualsiasi problema di ottimizzazione P abbiamo che

$$v(D) \leq v(P)$$

Da cui definiamo la **strong duality** se $v(D) = v(P)$

Attenzione: La dualità forte non è verificata in generale

Teorema 5 - Condizione sufficiente per la dualità

Supponiamo f, h e g continue e differenziali, forniamo il primale P :

$$\begin{cases} \min f(x) \\ g(x) \leq 0 \\ h(x) = 0 \end{cases}$$

Sia P convesso, esiste un ottimo globale x^* e l'ACQ è verificata ALLORA:

1) $V(D) = V(P)$ e D ammette l'ottimo

2) (λ^*, μ^*) è l'ottimo per D sse (λ^*, μ^*) è un vettore dei moltiplicatori associati a x^*

Dimostrazione

$L(x, \lambda, \mu)$ è convessa perché abbiamo supposto P convesso.

Sia (λ^*, μ^*) un vettore dei moltiplicatori per x^* per il sistema KKT, ALLORA

$$\nabla_x L(x^*, \lambda^*, \mu^*) = \emptyset, \quad \lambda^* \geq 0, \quad (\lambda^*)^T g(x^*) = 0$$

$$V(D) \geq V(\lambda^*, \mu^*) = \inf_x L(x, \lambda^*, \mu^*) = \inf_x L(x^*, \lambda^*, \mu^*) =$$

\downarrow
L convessa

$$= f(x^*) + \underbrace{(\lambda^*)^T g(x^*)}_{=0} + \underbrace{(\mu^*)^T h(x^*)}_{=0} = f(x^*) = V(P) \geq V(D)$$

Ma dato che siamo partiti da $V(D)$ allora vale l'uguaglianza $V(P) = V(D)$ e (λ^*, μ^*) è l'ottimo per D .

SS invece (λ^*, μ^*) è una qualsiasi soluzione ottima per D **ALLORA**

$$\begin{aligned} f(x^*) &= v(P) = v(D) = \varphi(\lambda^*, \mu^*) = \inf_x L(x, \lambda^*, \mu^*) \leq \\ &\leq L(x^*, \lambda^*, \mu^*) = f(x^*) + (\lambda^*)^T g(x^*) + \underline{(\mu^*)^T h(x^*)} = \\ &= f(x^*) + (\lambda^*)^T g(x^*) \stackrel{=} \leq f(x^*) \end{aligned}$$

Ma $(\lambda^*)^T g(x^*) = 0$ e $\inf_x L(x, \lambda^*, \mu^*) = L(x^*, \lambda^*, \mu^*)$, da cui viene da se che:

$$\nabla_x L(x^*, \lambda^*, \mu^*) = 0$$

Ora che (λ^*, μ^*) sono una coppia di vettori moltiplicatori KKT associati a X^* .

TEOREMA - Caratterizzazione della dualità forte
 (x^*, λ^*, μ^*) è un punto di sella per L , ovvero:

$$L(x^*, \lambda, \mu) \leq L(x^*, \lambda^*, \mu^*) \leq L(x, \lambda^*, \mu^*)$$

$$\forall x \in \mathbb{R}^m, \quad \forall \lambda \in \mathbb{R}_+^m, \quad \forall \mu \in \mathbb{R}^p$$

SSD x^* è ottimo per P , (λ^*, μ^*) è ottimo per D e $v(P) = v(D)$.