


REGRESSIONE

POLINOMIO DI REGRESSIONE

Dati e dati sperimentali $y_1 \dots y_p \in \mathbb{R}$ che corrispondono ai dati $x_1 \dots x_n \in \mathbb{R}$ osservati:



Con la regressione vogliamo trovare la migliore approssimazione dei punti osservati, tramite un polinomio p di grado $(n-1)$ con $n \leq p$.

Il polinomio p è nella forma:

$$p(x) = z_1 + z_2 x + z_3 x^2 + \dots + z_n x^{n-1}$$

RESIDUAL

Chiamiamo residual la differenza fra il valore del polinomio di approssimazione in x_i e il valore del punto osservato in x_i :

$$z_i = p(x_i) - y_i$$

Obiettivo: trovare $z = (z_1, \dots, z_n) : \|z\|$ sia minima:

$$\begin{cases} \min \|Az - y\| \\ z \in \mathbb{R}^n \end{cases}$$

Dove:

$$A = \begin{bmatrix} 1 & x_1 & \dots & x_1^{n-1} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_\ell & \dots & x_\ell^{n-1} \end{bmatrix} \in \mathbb{R}^{\ell \times n}, \quad y = \begin{bmatrix} y_1 \\ \vdots \\ y_\ell \end{bmatrix}$$

Funzione obiettivo:

$$f(z) = \|Az - y\| \quad \text{Convessa}$$

POLINOMIO DI REGRESSIONE CON $\|\cdot\|_2$

Data A **matrice di Vandermonde**, sopra descritta, abbiamo il seguente problema di programmazione quadratica non vincolato:

$$\begin{cases} \min \frac{1}{2} \|Az - y\|_2^2 \\ z \in \mathbb{R}^n \end{cases}$$

Dove, sviluppando la norma euclidea

$$\begin{aligned} \frac{1}{2} \|Az - y\|_2^2 &= \frac{1}{2} (Az - y)^T (Az - y) = \frac{1}{2} (z^T A^T A z - z^T A^T y - A z y + y^T y) \\ &= \frac{1}{2} z^T A^T A z - z^T A^T y + \frac{1}{2} y^T y \end{aligned}$$

Possiamo provare che $\text{rank}(A) = n$ e che $A^T A > 0$.

Dato che l'unica soluzione ottima del sistema con $\|\cdot\|_2$ è il punto stazionario della funzione obiettivo, la soluzione del sistema è:

$$f'(z) = 0$$

$$A^T A z - A^T y = 0$$

$$A^T A z = A^T y$$

$$z = (A^T A)^{-1} A^T y$$

POLINOMIO DI REGRESSIONE CON $\|\cdot\|_1$

Ora abbiamo un problema di programmazione lineare:

$$\begin{cases} \min & \frac{1}{2} \|Az - y\|_1 \\ z \in \mathbb{R}^n \end{cases}$$

Dove, sviluppando la $\|\cdot\|_1$:

$$\frac{1}{2} \|Az - y\|_1 = \sum_{i=1}^e |A_i z - y_i|$$

Il sistema precedente è equivalente del risolvere:

$$\begin{cases} \min \sum_{i=1}^e u_i \\ u_i = \|A_i z - y_i\|_1 = \max(A_i z - y_i, y_i - A_i z) \end{cases}$$

$$\begin{cases} \min \sum_{i=1}^{\ell} u_i \\ u_i \geq \max(A_i z - y_i, y_i - A_i z) \end{cases}$$

$$\begin{cases} \min \sum_{i=1}^{\ell} u_i \\ u_i \geq A_i z - y_i \\ u_i \geq y_i - A_i z \end{cases} \quad \forall i=1 \dots \ell$$

In forma vettoriale, quest'ultimo sistema si trasforma

$$\begin{cases} \min e^T u \\ Az - u \leq y \\ -Az - u \leq -y \end{cases}$$

Con $e^T = (1, \dots, 1) \in \mathbb{R}^{\ell}$.

Settando:

$$D = \begin{pmatrix} A & -I_{\ell} \\ -A & -I_{\ell} \end{pmatrix}, \quad d = \begin{pmatrix} y \\ -y \end{pmatrix}$$

Abbiamo il sistema finale:

$$\begin{cases} \min_{z, u} (\phi_m^T, e_m^T) \begin{pmatrix} z \\ u \end{pmatrix} \\ D \begin{pmatrix} z \\ u \end{pmatrix} \leq d \end{cases}$$

POLINOMIO DI REGRESSIONE CON $\|\cdot\|_\infty$

Abbiamo un problema di programmazione lineare:

$$\begin{cases} \min \|Az - y\|_\infty \\ z \in \mathbb{R}^n \end{cases}$$

$$\|Az - y\|_\infty = \max |A_i z - y_i|$$

Che è uguale a

$$\begin{cases} \min_{z, u} u \\ u = \max_{i=1 \dots \ell} |A_i z - y_i| \end{cases} \rightarrow \begin{cases} \min_{z, u} u \\ u \geq A_i z - y_i \\ u \geq y_i - A_i z \end{cases} \quad \forall i=1 \dots \ell$$

Settando

$$D = \begin{pmatrix} A & -e_\ell \\ -A & -e_\ell \end{pmatrix}, \quad d = \begin{pmatrix} y \\ -y \end{pmatrix}$$

Abbiamo


$$\begin{cases} \min_{z, u} (0, \dots, 0, 1) \begin{pmatrix} z \\ u \end{pmatrix} \\ D \begin{pmatrix} z \\ u \end{pmatrix} \leq d \end{cases}$$

Con n scalari

ϵ -SV REGRESSION

Dato un set di punti di training $\{(x_1, y_1) \dots (x_\ell, y_\ell)\}$ dove $x_i, y_i \in \mathbb{R}^n$, e dato $\epsilon > 0$, nella regressione di tipo ϵ -SV, l'obiettivo è trovare la funzione f :

$$|f(x_i) - y_i| \leq \epsilon \quad \forall i=1 \dots \ell$$



ϵ -tube
regression

ϵ -SV LINEARS

Nel caso lineare consideriamo la funzione affine f :

$$f(x) = w^T x + b \quad \text{e} \quad \epsilon > 0$$

Vogliamo che $f(x)$ sia "piatta", o per meglio dire, che abbia pendenza $w \rightarrow 0$. Però vogliamo rispettare anche che i punti siano compresi fra $\pm \epsilon$ rispetto al nostro iperpiano ($-\epsilon \leq w^T x_i + b - y_i \leq \epsilon$), da cui il sistema:

$$\begin{cases} \min \frac{1}{2} \|w\|^2 \\ y_i \leq w^T x_i + b + \epsilon \\ y_i \geq w^T x_i + b - \epsilon \end{cases} \quad \forall i=1 \dots \ell$$

In forma vettoriale definiamo

$$Q = \begin{pmatrix} I_e & \emptyset \\ \emptyset_e^T & \emptyset \end{pmatrix}, \quad D = \begin{pmatrix} -x & -e_e \\ x & e_e \end{pmatrix}, \quad d = \begin{pmatrix} \varepsilon e_e - y \\ \varepsilon e_e + y \end{pmatrix}$$

Da cui il sistema:

$$\begin{cases} \min_{w, b} \frac{1}{2} (w^T, b) Q \begin{pmatrix} w \\ b \end{pmatrix} \\ D \begin{pmatrix} w \\ b \end{pmatrix} \leq d \end{cases}$$

LINEAR ϵ -SV con variabili di rilassamento

Potrebbe succedere che ϵ sia troppo piccolo, e per tanto il modello non sia abbastanza flessibile. Estendiamo il modello aggiungendo le variabili "slack" o di rilassamento ξ_i^\pm :

$$\begin{cases} \min \frac{1}{2} \|w\|^2 + C \sum_{i=1}^e (\xi_i^+ + \xi_i^-) \\ y_i \leq w^T x_i + b + \epsilon + \xi_i^+ \\ y_i \geq w^T x_i + b - \epsilon - \xi_i^- \end{cases} \quad \forall i=1 \dots e$$

Dove il parametro C fa da trade-off fra la piattezza di $f(x)$ e la tolleranza su quanto deviare da ϵ .

$$\begin{cases} \min_{w,b} \frac{1}{2} (w^T, b, (\xi^+)^T, (\xi^-)^T) Q1 \begin{pmatrix} w \\ b \\ \xi^+ \\ \xi^- \end{pmatrix} + c^T \begin{pmatrix} w \\ b \\ \xi^+ \\ \xi^- \end{pmatrix} \\ D1 \begin{pmatrix} w \\ b \\ \xi^+ \\ \xi^- \end{pmatrix} \leq d1 \\ \xi^+ \geq 0, \xi^- \geq 0 \end{cases}$$

$$Q1 = \begin{pmatrix} I_n & 0_n & 0_{n \times 2\ell} \\ 0_n^T & 0 & 0_{2\ell}^T \\ 0_{2\ell \times n} & 0_{2\ell} & 0_{2\ell \times 2\ell} \end{pmatrix} \quad c^T = (0_n^T, 0, C * e_\ell^T, C * e_\ell^T)$$

$$D1 = \begin{pmatrix} -x & -e_\ell & -I_\ell & 0_{\ell \times \ell} \\ x & e_\ell & 0_{\ell \times \ell} & -I_\ell \end{pmatrix} \quad d = \begin{pmatrix} \epsilon e_\ell - y \\ \epsilon e_\ell + y \end{pmatrix}$$

DUALS

Vediamo adesso il duale ε -SV lineare con variabili di rilassamento.

Iniziamo definendo la Lagrangiana

$$\begin{aligned} L(w, b, \xi^+, \xi^-, \lambda^+, \lambda^-, \eta^+, \eta^-) = \\ = \frac{1}{2} \|w\|^2 - w^T \left[\sum_{i=1}^e (\lambda_i^+ - \lambda_i^-) x_i \right] - b \sum_{i=1}^e (\lambda_i^+ - \lambda_i^-) \\ + \sum_{i=1}^e \xi_i^+ (C - \lambda_i^+ - \eta_i^+) + \sum_{i=1}^e \xi_i^- (C - \lambda_i^- - \eta_i^-) \\ - \varepsilon \sum_{i=1}^e (\lambda_i^+ + \lambda_i^-) + \sum_{i=1}^e \gamma_i (\lambda_i^+ - \lambda_i^-) \end{aligned}$$

$$\text{SS } \sum_{i=1}^e (\lambda_i^+ - \lambda_i^-) \neq 0$$

$$\text{oppure } (C - \lambda_i^+ - \eta_i^+) \neq 0$$

$$\text{oppure } (C - \lambda_i^- - \eta_i^-) \neq 0 \quad \text{per qualche } i$$

ALLORA:

$$\min_{w, b, \xi^+, \xi^-} L = -\infty$$

ALTRIMENTI:

$$1) \nabla_w L = w - \sum_{i=1}^e (\lambda_i^+ - \lambda_i^-) x_i = 0$$

Da cui ricaviamo, sotto queste condizioni:

$$w = \sum_{i=1}^e (\lambda_i^+ - \lambda_i^-) x_i$$

Allo stesso modo possiamo calcolare:

$$2) \nabla_{\lambda} L = - \sum_{i=1}^{\ell} (\lambda_i^+ - \lambda_i^-) = 0$$

$$3) \nabla_{\eta_i^+} L = C - \lambda_i^+ - \eta_i^+ = 0 \implies \eta_i^+ = C - \lambda_i^+$$

$$4) \nabla_{\eta_i^-} L = C - \lambda_i^- - \eta_i^- = 0 \implies \eta_i^- = C - \lambda_i^-$$

Note: Questi ultimi 3 gradienti sono i vincoli del duale.

Sostituendo $w = \sum_{i=1}^{\ell} (\lambda_i^+ - \lambda_i^-) x_i$ alla Lagrangiana abbiamo che il sistema duale è:

$$\left\{ \begin{array}{l} \max_{\lambda^+, \lambda^-, \eta^+, \eta^- \geq 0} -\frac{1}{2} \sum_{i=1}^{\ell} \sum_{j=1}^{\ell} (\lambda_i^+ - \lambda_i^-) (\lambda_j^+ - \lambda_j^-) (x_i)^T x_j \\ \quad - \varepsilon \sum_{i=1}^{\ell} (\lambda_i^+ + \lambda_i^-) + \sum_{i=1}^{\ell} y_i (\lambda_i^+ - \lambda_i^-) \\ \sum_{i=1}^{\ell} (\lambda_i^+ - \lambda_i^-) = 0 \\ C - \lambda_i^+ - \eta_i^+ = 0, \quad i = 1, \dots, \ell \\ C - \lambda_i^- - \eta_i^- = 0, \quad i = 1, \dots, \ell \end{array} \right.$$

Notando che $C = \lambda_i^+ + \eta_i^+$ e $C = \lambda_i^- + \eta_i^-$ possiamo riscrivere che $\lambda_i^{\pm} \in [0, C]$:

$$\left\{ \begin{array}{l} \max_{\lambda^+, \lambda^-} -\frac{1}{2} \sum_{i=1}^{\ell} \sum_{j=1}^{\ell} (\lambda_i^+ - \lambda_i^-) (\lambda_j^+ - \lambda_j^-) (x_i)^T x_j \\ \quad - \varepsilon \sum_{i=1}^{\ell} (\lambda_i^+ + \lambda_i^-) + \sum_{i=1}^{\ell} y_i (\lambda_i^+ - \lambda_i^-) \\ \sum_{i=1}^{\ell} (\lambda_i^+ - \lambda_i^-) = 0 \\ \lambda_i^+ \in [0, C], \quad i = 1, \dots, \ell \\ \lambda_i^- \in [0, C], \quad i = 1, \dots, \ell \end{array} \right.$$

In forma vettoriale:

$$\begin{cases} \max_{\lambda^+, \lambda^-} -\frac{1}{2}((\lambda^+)^T, (\lambda^-)^T) Q \begin{pmatrix} \lambda^+ \\ \lambda^- \end{pmatrix} + [-\epsilon(e_\ell^T, e_\ell^T) + (y^T, -y^T)] \begin{pmatrix} \lambda^+ \\ \lambda^- \end{pmatrix} \\ (e_\ell^T, -e_\ell^T) \begin{pmatrix} \lambda^+ \\ \lambda^- \end{pmatrix} = 0 \\ \lambda_i^+ \in [0, C], \quad i = 1, \dots, \ell \\ \lambda_i^- \in [0, C], \quad i = 1, \dots, \ell \end{cases}$$

Con $Q = \begin{pmatrix} X & -X \\ -X & X \end{pmatrix}$ e $X = [(x_i)^T x_j] \quad i, j = 1 \dots \ell$

Nota:

1) Il duale è un problema convesso

2) SS $\lambda_i^+ > 0$ o $\lambda_i^- > 0$ ALLORA $x_i =$ support vector

3) SS (λ^+, λ^-) è ottimo del duale ALLORA

$$w = \sum_{i=1}^{\ell} (\lambda_i^+ - \lambda_i^-) x_i$$

4) b si ottiene usando

$$\begin{cases} \lambda_i^+ (\epsilon + \xi_i^+ - y_i + w^T x_i + b) = 0 \\ \lambda_i^- (\epsilon + \xi_i^- + y_i - w^T x_i - b) = 0 \\ \xi_i^+ (C - \lambda_i^+) = 0 \\ \xi_i^- (C - \lambda_i^-) = 0 \end{cases}$$

Da cui fissando $0 < \lambda_i^\pm < C$:

$$b = y_i - w^T x_i \mp \epsilon$$

KERNEL

Uguale identico, sostituendo x_i con $\phi(x_i)$