

ATTRIBUTE SELECTION

A volte possiamo ridurre le dimensioni del Dataset omettendo alcuni attributi che risultano inutili o ridondanti (Spesso ricavabili da altri attributi).

APPROCCIO GREEDY

Con d attributi si possono avere 2^d combinazioni

Esempio:

Se ho due attributi A e B, posso fare $2^2 = 4$ combinazioni:

- 1) Prendo AB
- 2) Prendo A
- 3) Prendo B
- 4) Non prendo nessuno

Fra i possibili approcci greedy, abbiamo:

- 1) **Best single attribute**: sotto l'assunzione che tutti gli attributi sono indipendenti, sceglierli secondo quel test significativo
- 2) **Best step-wise features selection**: selezionare a ogni step l'attributo migliore
- 3) **Best step-wise features elimination**: partire da tutti e a ogni passo eliminare i peggiori
- 4) **Combinare i precedenti approcci**

APPROCCIO EURISTICO CON MUTUAL INFORMATION

Consideriamo due variabili Discrete X e Y , definiamo X_X e Y_Y tutti i possibili valori di X e Y

Definiamo $I(X, Y)$, *mutual information* come:

$$I(X, Y) = \sum_{x \in X} \sum_{y \in Y} p(x, y) \cdot \log \frac{p(x, y)}{p(x)p(y)}$$

Dove $p(x, y)$ è la probabilità congiunta, ovvero la probabilità che sia $X=x$ e $Y=y$.

Mentre $p(x)$ e $p(y)$ sono le probabilità marginali, indipendenti fra loro.

ENTROPIA

Data una distribuzione D e per ogni valore di D le corrispondenti probabilità che si verificano, definiamo l'entropia come:

$$H(D) = - \sum_i p_i \log_2 p_i$$

Proprietà del MI:

- 1) Capacità di misurare ogni tipo di relazione fra le variabili interessate
- 2) Non varia se si cambia lo spazio (traslazione, rotazione, ecc...) basta non variare l'ordine del dataset originale)

Come fare con un dataset con classi.

Dato un set iniziale F con n attributi, bisogna trovare un sottoinsieme $S \subset F$ con k attributi che massimizza il $I(C, S)$, dove C è la classe variabile.

PASSI

1) Inizializzare F e S :

- F = Set iniziali con n attributi
- S = vuoto

2) Calcolare $I(C, f_i) \quad \forall f_i \in F$

3) Selezionare il primo attributo f_i che massimizza M_1
Setta:

- $F \leftarrow F / \{f_i\}$
- $S \leftarrow \{f_i\}$

4) Selezionare gli attributi diversi dal primo:

- Calcolare M_1 per ogni coppia (f_i, f_s) dove $f_i \in F$ e $f_s \in S$.

- Selezionare la feature che massimizza

$$I(C, f_i) - \frac{1}{|S|} \sum_{f_s \in S} NI(f_s, f_i)$$

SST:

- $F \leftarrow F / \{f_i\}$
- $S \leftarrow \{f_i\}$

Ripetere finché $|S| = k$

5) Abbiamo il nostro risultato S .

NORMALIZZANDO

Normalizziamo MI :

$$NI(f_i, f_s) = \frac{I(f_i, f_s)}{\min\{H(f_i), H(f_s)\}}$$

FOCUS su $-\frac{1}{|S|} \sum_{f_s \in S} NI(f_s, f_i)$

È una sorta di misura di correlazione fra f_s e f_i . Più è vicina a 0 più f_i è indipendente dal sottoinsieme di features in S . Vicino a 1 è indice di correlazione.

Difatti è la media di tutti i MI fra f_i e ogni elemento in S . Termine additivo.